


1 Вступ до науки про дані

Наука про дані (Data Science) - використовує наукові методи, алгоритми та комп'ютерні системи для витягнення інформації та важливих висновків із величезних масивів інформації.

Простіше кажучи, це процес перетворення сирих хаотичних даних (цифр, текстів, зображень) на зрозумілі відповіді, які допомагають приймати кращі рішення.

Для того, щоб стати фахівцем у цій сфері, потрібно вивчити три основні дисципліни: **математика та статистика** - допомагає краще розуміти закономірності, швидше перевіряти гіпотези; **комп'ютерні науки** - надають інструменти для швидкої/напіваавтоматичної обробки даних; **знання предметної області** - дозволяє краще розуміти контекст (медицина, економіка), ставити правильні запитання.




Наука про дані тісно пов'язана з такими напрямками та технологіями:

- Великі дані (Big Data) - обробка та зберігання інформаційних масивів, обсяг яких перевищує можливості стандартного програмного забезпечення
- Штучний інтелект (Artificial Intelligence) - створення систем, здатних імітувати когнітивні функції людини для вирішення складних завдань
- Машинне навчання (Machine Learning) - розробка алгоритмів, які самостійно знаходять закономірності в даних без прямого програмування кожної дії
- Глибоке навчання (Deep Learning) - використання багатoshарових нейронних мереж для аналізу складних структур, таких як мова або зображення
- Інтернет речей (Internet of Things) - інтеграція інтелектуальних алгоритмів у фізичні пристрої (холодильники, мультиварки, кондиціонери) для аналізу даних у реальному часі. Наприклад кондиціонер з ШІ може не тільки вмикатись за розкладом, а й самостійно аналізувати вологість і підлаштовувати температуру
- Генеративний ШІ (Generative AI) - створення моделей, здатних генерувати новий контент (текст, зображення, код) на основі існуючих даних
- Агентний ШІ (Agentic AI) - розробка автономних систем, що здатні діяти самостійно для досягнення поставлених цілей. Наприклад користувач задає команду

«Організуй мені поїздку на вихідні», агентний ШІ сам знайде готель, забронює квитки, перевірить погоду і скине готовий маршрут у календар.

Великі дані (Big Data)

Великі дані – це масиви інформації настільки величезного обсягу та складної структури, що їх неможливо ефективно обробити, зберегти або проаналізувати за допомогою традиційних методів програмування та баз даних.



Великі дані визначаються трьома основними ознаками (3V): **обсяг (volume)** – величезна кількість даних, які генеруються кожної секунди; **різноманітність (variety)** – дані надходять у різних форматах, від структурованих таблиць до неструктурованих текстових повідомлень, аудіо, сигналів із датчиків тощо; **швидкість (velocity)** – швидкість, з якою дані створюються, передаються та потребують аналізу.

Штучний інтелект (Artificial Intelligence)

Штучний інтелект – це симуляція роботи людського мозку. Це дуже широкий термін, застосовується у багатьох галузях від фільтрів спаму в електронній пошті до автономних роботів.

Машинне навчання (Machine Learning)

Машинне навчання – це галузь штучного інтелекту, яка надає комп'ютерним системам здатність автоматично навчатися та вдосконалюватися на основі досвіду без явного програмування.

Том Мітчелл запропонував формулу: програма навчається, якщо вона виконує Завдання, накопичує Досвід і завдяки цьому її Результат стає кращим.

Наприклад, у грі в шахи завданням є сама гра проти суперника, досвідом стає кількість усіх зіграних партій, а показником успіху вважається ймовірність виграшу. Якщо з

кожною новою партією програма починає перемагати частіше, це означає, що вона успішно навчається на власному досвіді.

Глибоке навчання (Deep Learning)

Глибоке навчання - це вдосконалений метод машинного навчання, який дозволяє комп'ютеру вирішувати дуже складні завдання - розпізнавати обличчя на фото, перекладати людську мову в реальному часі. Свою назву воно отримало через використання глибоких нейронних мереж.

Програма складається з багатьох простих блоків, з'єднаних між собою. Вона пропускає крізь ці блоки величезні обсяги даних, поступово навчаючись бачити в них складні образи.

Основні типи нейронних мереж: **класична** - підходить для вирішення загальних завдань вроді оцінки вартості нерухомості; **згортова** - найкраще розуміє картинки та відео, використовується у камерах смартфонів та автопілотах; **рекурентна** - спеціалізується на роботі з послідовностями, використовується для аналізу тексту або передбачення коливання цін; **трансформери** - для великих мовних моделей як ChatGPT, створення текстів та перекладу.

Інтернет речей (Internet of Things)

Зв'язок між штучним інтелектом та Інтернетом речей схожий на зв'язок між людським мозком та тілом. Інтернет речей робить ШІ кращим (через дані), а ШІ робить Інтернет речей кориснішим (через дію).

На практиці це допомагає запобіганню аваріям - датчики на мосту (Internet of Things) фіксують мікрівібрації, а ШІ аналізує їх і попереджає про ризик руйнування ще до того, як з'являться видимі тріщини.

Чи наприклад в медицині - розумний браслет (Internet of Things) міряє пульс, а ШІ помічає в ньому аномальний ритм і може самостійно викликати швидку, якщо розпізнає ознаки серцевого нападу.

Генеративний ШІ (Generative AI)


Комп'ютер вивчає закономірності з існуючих даних та використовує їх для створення нового контенту, подібного до того, що він бачив раніше. Широко використовується в дизайні (генерація варіантів логотипу), та програмуванні (написання коду, наприклад функції авторизації)

Агентний ШІ (Agentic AI)

Системі достатньо поставити кінцеву мету, вона сама розпланує шлях, прийме необхідні рішення та виконає дії для її досягнення. Широко використовується у бізнесі (аналізує ринок, запускає рекламну компанію, відстежує результати) та побуті (розумний дім який сам замовляє продукти чи викликає майстра).

Які мови варто вивчати першими

Приклади в книзі написані на мові Python, так як це дуже популярна мова у сфері науки про дані.




1.1 Типи машинного навчання

Машинне навчання ділиться на три основні типи: навчання з учителем (Supervised), навчання без учителя (Unsupervised), навчання з підкріпленням (Reinforcement).

Навчання з учителем (Supervised)

Комп'ютер вчиться на прикладах, де вже є правильні відповіді, їх називають мітками. Таким чином модель виявляє математичну залежність і може прогнозувати відповіді для нових об'єктів.




Головні типи завдань такої моделі:

класифікація – коли результатом є категорія (так/ні, спам/не спам, кіт/собака); **регресія** – коли результатом є конкретне число (ціна квартири, курс долара, температура)

Популярні інструменти для такої моделі: **лінійна регресія** – знаходить пряму лінію, яка краще описує зв'язок між параметрами (як площа квартири впливає на її ціну); **дерева рішень** – розбивають дані на послідовні запитання «так/ні», створюючи логічну структуру для прийняття рішень; **метод опорних векторів** – будує кордон, або її називають гіперплощиною, який максимально чітко розподіляє два класи об'єктів у просторі.

Навчання без учителя (Unsupervised)



Комп'ютер вчиться на прикладах, де вже немає жодних міток, тому він самостійно аналізує інформацію. Таким чином модель виявляє приховані закономірності, аномалії, або групує дані за схожістю.


Головні типи завдань такої моделі: **кластеризація** – розділення даних на групи (розбити всіх клієнтів магазину на групи за схожими звичками); **зменшення розмірності** – спрощення складних даних без втрати головного змісту; **системи рекомендацій** – коли сервіс підбирає музику чи товари, схожі на ті, що вже купували.

Популярні інструменти для такої моделі: **К-середні (K-Means)** – для групування; **Аналіз головних компонентів (PCA)** – для стиснення даних.

Навчання з підкріпленням (Reinforcement)

Навчання через взаємодію комп'ютера з середовищем. Програма не знає правильної відповіді, але отримує зворотний зв'язок на свої дії. Таким чином модель знаходить оптимальну послідовність дій, яка максимізує сумарну винагороду та мінімізує штрафи.

Застосовується така модель зазвичай в автопілотах, або при навчанні роботів ходити.



1.2 Робоче середовище

Для реалізації алгоритмів машинного навчання знадобиться інтерпретатор мови Python та інтерактивне середовище розробки. Усі наведені інструкції та комбінації клавіш актуальні для Windows. Користувачам macOS та Linux рекомендується звернутись до інтернету для пошуку аналогів.

По-перше, інсталюємо базовий інтерпретатор. Для цього перейдіть на офіційний сайт <https://www.python.org/> у розділ Downloads. Завантажте останню стабільну версію Python (в подальших лістингах використовується Python 3.14.0). Під час запуску інсталлятора поставте галочку «Add Python to PATH» - це дозволить запускати Python з будь-якої папки через командний рядок.

Щоб переконатись, що система бачить командний рядок: натисніть комбінацію клавіш Win + R, введіть cmd та натисніть Enter. У вікні, що відкрилося, введіть команду:

```
python --version
```

Якщо система видасть номер версії, наприклад Python 3.14.0 - вітаєм, усе встановлено правильно.

Для роботи в Data Science стандартним інструментом є Jupyter Lab. Це середовище дозволяє писати код окремими блоками (клітинками) і одразу бачити результат.


Для надійної інсталяції через менеджер пакетів рекомендується використовувати прямий виклик через модуль Python:

```
py -m pip install jupyterlab
```

Щоб розпочати роботу, у тому ж командному рядку введіть:

```
py -m jupyter lab
```

Після цього в браузері відкриється вкладка з інтерфейсом середовища.



Щоб створити новий файл - натисніть на іконку Python 3 (ipykernel) у розділі Notebook. Файли матимуть розширення .ipynb. Для створення клітинки натисніть кнопку «+» на панелі інструментів. Щоб виконати код у клітинці, натисніть Shift + Enter - це виконає поточний блок і перейде до наступного. Клітинки можуть бути як для Code (програмний код), так і для Markdown (текстові описи та заголовки).

