

4. Логістична регресія та SVM

У цьому розділі ми переходимо від прогнозування чисел до класифікації об'єктів. Розглядаються два популярні алгоритми класифікації: логістична регресія (Logistic Regression) та метод опорних векторів (Support Vector Machine)

Перед початком роботи з алгоритмами класифікації необхідно підключити бібліотеки,

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.metrics import classification_report, confusion_matrix,
ConfusionMatrixDisplay
from sklearn.preprocessing import StandardScaler
```

які відповідають за обчислення, підготовку даних, побудову моделей класифікації та оцінку їх якості:

- **make_classification** - генератор штучних даних для задач класифікації. Дозволяє швидко створити набір ознак та міток класів;
- **LogisticRegression** - реалізація алгоритму логістичної регресії для бінарної та мультикласової класифікації;
- **SVC (Support Vector Classifier)** - реалізація методу опорних векторів (SVM), який шукає оптимальну межу між класами;
- **classification_report** - інструмент для виведення основних метрик класифікації: precision, recall, f1-score та accuracy;
- **confusion_matrix** - створює матрицю помилок класифікації;
- **ConfusionMatrixDisplay** - використовується для графічного відображення confusion matrix.

Суть класифікації та логістична регресія

У задачах класифікації модель повинна визначити, до якого класу належить об'єкт. Тобто, якщо регресія повертає дійсне число, то класифікація прогнозує категорію.

```
X, y = make_classification(n_samples=500, n_features=2, n_redundant=0,
                           n_clusters_per_class=1, random_state=42)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
                                                    random_state=42)

scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Тут `make_classification` створює: 500 об'єктів (`n_samples=500`), кожен об'єкт містить дві ознаки (`n_features=2`), немає лінійно залежних ознак (`n_redundant=0`), кожен клас створює один кластер точок (`n_clusters_per_class=1`).

Основою логістичної регресії є сигмоїдна функція (sigmoid function):

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Функція приймає будь-яке число та повертає значення від 0 до 1. Наприклад 0.95 - модель майже впевнена у класі 1, 0.10 - ймовірніше клас 0.

Після обчислення ймовірності модель формує Decision Boundary - межу прийняття рішень, яка розділяє класи у просторі ознак. Для логістичної регресії вона зазвичай є прямою лінією:

$$w_1x_1 + w_2x_2 + b = 0$$

Модель намагається знайти таку межу, щоб максимально добре розділити об'єкти різних класів.

Метрики якості класифікації

Після підготовки даних та масштабування можна перейти до навчання моделі логістичної регресії.

```
log_reg = LogisticRegression()
log_reg.fit(X_train_scaled, y_train)

print("--- Logistic Regression Results ---")
y_pred_log = log_reg.predict(X_test_scaled)
print(classification_report(y_test, y_pred_log))
```

Загальна точність (Accuracy) показує частку правильних відповідей.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Але якщо дані не збалансовані (один клас зустрічається набагато частіше за інший), загальна точність може бути оманливою. Наприклад, якщо 95% листів - це звичайні повідомлення, а лише 5% - спам, модель може завжди відповідати «не спам» і все одно отримати accuracy 95%. Хоча насправді така модель нічому не навчилась.

Матриця помилок (Confusion Matrix) - таблиця помилок класифікації, містить: **TP (True Positive)** - правильне визначення позитивного класу; **TN (True Negative)** - правильне визначення негативного класу; **FP (False Positive)** - клас хибно визначено позитивним; **FN (False Negative)** - клас хибно визначено негативним.

Точність (Precision) - показує, скільки позитивних прогнозів були правильними.

$$Precision = \frac{TP}{TP + FP}$$

Повнота (Recall) - показує, скільки реальних позитивних об'єктів знайшла модель.

$$Recall = \frac{TP}{TP + FN}$$

Тобто, припустимо є 100 листів, 10 з них - спам. Модель позначила як спам 8 листів, але з цього її списку лише 5 виявилися дійсно спамом. Тоді:

$$Precision = \frac{5}{8}$$

$$Recall = \frac{5}{10}$$

Наскільки можна довіряти позитивним прогнозам моделі?

Яку частину всього спаму модель змогла знайти?

F1-score поєднує precision та recall:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Ця метрика особливо корисна для незбалансованих даних.

Метод опорних векторів (SVM)

SVM (Support Vector Machine) шукає гіперплощину, яка максимально добре розділяє класи. Головна мета - не просто повернути межу, а зробити максимальний зовнішній відступ (margin) між класами.

```
svm_model = SVC(kernel='linear', C=1.0, probability=True)
svm_model.fit(X_train_scaled, y_train)

print("--- SVM Results ---")
y_pred_svm = svm_model.predict(X_test_scaled)
print(classification_report(y_test, y_pred_svm))
```

SVC() створює модель методу опорних векторів. Тут: `kernel='linear'` - використовується лінійна межа розділення; `C=1.0` - параметр регуляризації; `probability=True` - дозволяє моделі оцінювати ймовірність класів.

Під час навчання SVM намагається знайти оптимальну межу між класами з максимальним margin. Margin (зовнішній відступ) - це відстань між decision boundary та найближчими точками.

$$Margin = \frac{2}{\|w\|^1}$$

Чим більший margin, тим стабільнішою зазвичай є модель на нових даних.

Після навчання використовується:

```
y_pred_svm = svm_model.predict(X_test_scaled)
```

Метод predict() - прогнозує класи для тестової вибірки.

¹ $\|w\|$ - довжина (норма) вектора.

Опорні вектори (support vectors) - це точки, які знаходяться найближче до межі. Саме вони визначають положення decision boundary. Якщо видалити інші точки, то межа майже не зміниться.

Параметр C контролює баланс між шириною margin та кількістю помилок класифікації. Чим більше C - тим менше помилок допускає модель, але більший ризик перенавчання.


Якщо дані не можна розділити прямою лінією, використовується kernel trick. Kernel переводить дані у простір вищої розмірності, де вони вже можуть бути лінійно роздільними.

У SVM доступні різні типи kernel: **linear** - лінійна межа; **rbf** - нелінійна межа; **poly** - поліноміальна межа.

Візуалізація Decision Boundary

Візуальне порівняння логістичної регресії та SVM:

```
def plot_decision_boundary(model, X, y, title):  
    h = .02  
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1  
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1  
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h), np.arange(y_min, y_max, h))  
  
    Z = model.predict(np.c_[xx.ravel(), yy.ravel()])  
    Z = Z.reshape(xx.shape)  
  
    plt.contourf(xx, yy, Z, alpha=0.3, cmap=plt.cm.coolwarm)  
    plt.scatter(X[:, 0], X[:, 1], c=y, edgecolors='k',  
cmap=plt.cm.coolwarm)  
    plt.title(title)  
    plt.show()  
  
plot_decision_boundary(log_reg, X_test_scaled, y_test, "Logistic  
Regression Boundary")  
plot_decision_boundary(svm_model, X_test_scaled, y_test, "SVM Boundary")
```



Функція `plot_decision_boundary()` створює сітку точок у просторі ознак та визначає, до якого класу модель відносить кожну точку.

Для цього: `meshgrid()` - створює координатну сітку; `predict()` - класифікує всі точки сітки; `contourf()` - зафарбовує області різних класів; `scatter()` - відображає реальні точки даних.

Матриця помилок

Для детального аналізу роботи класифікатора використовується `confusion matrix` - матриця помилок класифікації.

```
print("--- Візуалізація помилок (Confusion Matrix) ---")
ConfusionMatrixDisplay.from_estimator(svm_model, X_test_scaled, y_test,
                                     cmap='Blues')
plt.show()
```


`ConfusionMatrixDisplay.from_estimator()` автоматично виконує прогнозування, обчислює матрицю помилок та будує її графічне відображення.

Тут: `svm_model` - навчена модель класифікації; `X_test_scaled` - тестові ознаки; `y_test` - правильні мітки класів; `cmap='Blues'` - кольорова схема візуалізації.

Після цього `plt.show()` відображає графік на екрані.

Зазвичай матриця помилок виглядає так:
 $\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$. Вона дозволяє оцінити кількість правильних прогнозів, побачити типи помилок моделі та визначити, який клас модель плутає найчастіше.

На відміну від звичайного асигасу, матриця помилок показує повну картину роботи класифікатора. Тому вона особливо важлива для незбалансованих даних.



Наприклад, у медичній діагностиці FN-помилки можуть бути критичними, оскільки модель пропускає хворобу. Тому матриця помилок допомагає оцінити не лише кількість помилок, а й їх тип та критичність.

Основні кольори для матриці помилок

Відтінкові (одноколірні) схеми			
Blues	синій	Reds	червоний
Greens	зелений	Purples	фіолетовий
Oranges	помаранчевий	Greys	сірий
Перехідні (градієнтні) схеми			
viridis	фіолетовий - зелений	plasma	фіолетовий - жовтий
inferno	чорний - червоний - жовтий	Magma	темний - рожево- фіолетовий
cividis	жовто-зелений		

Ресурси

Файл з наведеними лістингами: [Лекція 4. Логістична регресія та SVM.pdf](#)